

UNIVERSIDADE REGIONAL DE BLUMENAU
CENTRO DE CIÊNCIAS EXATAS E NATURAIS
CURSO DE CIÊNCIA DA COMPUTAÇÃO

Processamento de Linguagem Natural

Unidade 3 - Representações e Análise Linguística de Textos

Integrantes do grupo: Artur Lian, Matheus Voltolini, Nicolas Reiter

Link para repositório (GitHub, OneDrive etc.):

https://github.com/ArturTorres/FURB_PLN_Trabalhos

1. Representações de texto (1 ponto):

Tarefa	Foi implementada?	Comentários (opcional)
BoW	() Sim (X) Não	Não implementado devido à baixa capacidade semântica e dependência de palavras exatas.
TF-IDF (simples)	() Sim (X) Não	Testado, porém apresentou limitações na interpretação contextual dos sintomas.
TF-IDF (lematização e stemming)	() Sim (X) Não	Testado, apesar da melhora textual, ainda possui baixa compreensão semântica.
Word2Vec	() Sim (X) Não	Não implementado por apresentar menor desempenho contextual em comparação ao BERT.
BERT	(X) Sim () Não	Implementado por apresentar melhor compreensão semântica e contextual dos sintomas.

2.1. Cálculo e verificação de similaridade (2 pontos):

Quais as técnicas utilizadas? Qual a combinação (ex. TF-IDF simples + similaridade por cosseno) apresentou melhores resultados para o dataset? Incluir imagens/prints que demonstrem os resultados (heatmap, visualização em gráfico de dispersão com clusters etc.). Emitir parecer fundamentado.

Foi utilizada a técnica de embeddings com BERT combinada com similaridade por cosseno para calcular a proximidade semântica entre sintomas e doenças.

Os testes demonstraram que consultas semanticamente semelhantes apresentavam maior proximidade vetorial, mesmo quando escritas com palavras diferentes. O modelo baseado em BERT apresentou melhor generalização e recuperação de informações relevantes, principalmente em consultas descritivas.

	Anemia aplástica	Anemia perniciosa: o que é, sintomas e tratamento	Câncer de baço: veja como identificar e tratar essa doença rara	Disfunção da articulação temporomandibular (ATM): o que é e como tratar?	Disfunção erétil: conheça os sintomas, causas e tratamento	Fratura de costela	Gastrite atrófica: o que é e quais os sintomas	Hematúria (presença de sangue na urina)	Obesidade
Anemia aplástica	1.000000	0.896233	0.714391	0.622217	0.776812	0.843959	0.753141	0.858827	0.817472
Anemia perniciosa: o que é, sintomas e tratamento	0.896233	1.000000	0.712988	0.680067	0.849258	0.876608	0.735729	0.901544	0.866749
Câncer de baço: veja como identificar e tratar essa doença rara	0.714391	0.712988	1.000000	0.590058	0.714596	0.740951	0.767473	0.733970	0.719814
Disfunção da articulação temporomandibular (ATM): o que é e como tratar?	0.622217	0.680067	0.590058	1.000000	0.636510	0.650035	0.650436	0.600916	0.675203
Disfunção erétil: conheça os sintomas, causas e tratamento	0.776812	0.849258	0.714596	0.636510	1.000000	0.836216	0.695966	0.840756	0.823171
Fratura de costela	0.843959	0.876608	0.740951	0.650035	0.836216	1.000000	0.743383	0.898230	0.834860
Gastrite atrófica: o que é e quais os sintomas	0.753141	0.735729	0.767473	0.650436	0.695966	0.743383	1.000000	0.725116	0.762545
Hematúria (presença de sangue na urina)	0.858827	0.901544	0.733970	0.600916	0.840756	0.898230	0.725116	1.000000	0.854560
Obesidade	0.817472	0.866749	0.719814	0.675203	0.823171	0.834860	0.762545	0.854560	1.000000

2.2. Sistema de busca/recuperação de informação (entrada via query com recuperação de n documentos relevantes) (1,5 ponto):

O sistema é funcional e apresenta resultados com qualidade? Qual o desempenho com buscas curtas (termos exatos) e longas (frases, múltiplas palavras-chave etc.)? Explique e dê exemplos.

O sistema de busca apresentou resultados satisfatórios ao recuperar doenças relacionadas aos sintomas fornecidos pelo usuário.

Em buscas curtas, utilizando termos específicos como “febre” ou “tosse”, o sistema conseguiu identificar rapidamente doenças relacionadas. Em consultas mais longas, o BERT apresentou melhor desempenho ao compreender o contexto da frase.

2.3. Sistema de recomendação (1,5 ponto):

Os cálculos de similaridade permitiram produzir recomendações relevantes? Explique e dê exemplos.

Os cálculos de similaridade permitiram gerar recomendações relevantes entre doenças que compartilham sintomas semelhantes.

Por exemplo, sintomas como febre, tosse e fadiga aproximam doenças respiratórias semelhantes, enquanto dores musculares e indisposição podem indicar doenças virais relacionadas.

3. Parsing, NER e Análise de Sentimentos (1,5 ponto):

Tarefa	Foi implementada?	Tem usos potenciais para o dataset? Explique brevemente.
Parsing	(X) Sim () Não	Sim, o parsing ajuda a entender a estrutura gramatical dos textos de sintomas descritos pelos usuários. Permite extrair relações

		Sujeito-Verbo-Objeto (ex: "paciente relata fadiga"), identificar dependências sintáticas e normalizar dados textuais desestruturados, facilitando a posterior comparação com o dataset de doenças.
Named Entity Recognition	(X) Sim () Não	Sim, o NER identifica e extrai entidades nomeadas (nomes de doenças, medicamentos, locais) e features linguísticas (substantivos, verbos, adjetivos) dos textos. Permite categorizar e estruturar sintomas relatados, facilitando a busca e recuperação de informações relevantes no dataset.
Análise de sentimentos	() Sim (X) Não	

4. Retomando o primeiro trabalho (<https://ava3.furb.br/mod/forum/view.php?id=1294955>), avalie o progresso entre a proposta apresentada anteriormente e as atividades já implementadas com os dados textuais. Comente os progressos e obstáculos, assim como tarefas/funcionalidades que ainda não foram aplicadas e próximos passos possíveis (2,5 pontos).

Em relação à proposta inicial, houve evolução significativa no desenvolvimento do sistema de análise textual para identificação de doenças.

Inicialmente foram consideradas abordagens clássicas como BoW e TF-IDF, porém o modelo BERT apresentou resultados superiores devido à sua capacidade de compreender contexto e relações semânticas.

Entre os principais obstáculos encontrados estão o alto custo computacional do modelo BERT e a limpeza dos dados textuais.

Como próximos passos, pretende-se ampliar a base de dados, melhorar a interface do sistema e implementar reconhecimento de entidades médicas mais robusto.